Στατιστική Μοντελοποίηση και Αναγνώριση Προτύπων (ΤΗΛ311)

Αναφορά 2ης Σειράς Ασκήσεων

Ανδρεαδάκης Αντώνης 2013030059

Αναθεωρημένη έκδοση (Νοέμβριος 2026): οι ασκήσεις 4 (ερώτημα C), 5 και 7 ξαναγράφτηκαν μετά από διόρθωση του κώδικα και η άσκηση 6 προστέθηκε.

1. Λογιστική Παλινδρόμηση: Αναλυτική εύρεση κλίσης

Στην άσκηση αυτή, ασχοληθήκαμε με την αναλυτική εύρεση της κλίσης σε ένα σύνολο m δεδομένων $\{(\boldsymbol{x}^{(1)}, y^{(1)}), (\boldsymbol{x}^{(2)}, y^{(2)}), \dots, (\boldsymbol{x}^{(m)}, y^{(m)})\}$, όπου $\boldsymbol{x}^{(i)} \in \mathbb{R}^{n\times 1}$ είναι τα διανύσματα χαρακτηριστικών και $y^{(i)} \in \{0,1\}$ ορίζουν την κλάση κάθε δείγματος (labels).

A.

We know calculate the slope of the loss function $J(\theta)$ w.r.t the learnable parameters θ of our learner.

$$ln\Big(h_\theta(x^{(i)})\Big) = ln(\frac{1}{1+e^{-\theta^T x^{(i)}}}) = -ln(1+e^{-\theta^T x^{(i)}})$$

$$ln\Big(1-h_\theta(x^{(i)})\Big) = ln(1-\frac{1}{1+e^{-\theta^T x(i)}}) = ln(\frac{e^{-\theta^T x^{(i)}}}{1+e^{-\theta^T x^{(i)}}}) =$$
$$= ln(e^{-\theta^T x^{(i)}}) - ln(1+e^{-\theta^T x^{(i)}}) = -\theta^T x^{(i)} - ln(1+e^{-\theta^T x^{(i)}})$$

By substitution we get that

$$J(\theta) = \frac{1}{m}\sum_{i=1}^{m}\Big(y^{(i)} ln\Big(1+e^{-\theta^T x^{(i)}}\Big) + (1-y^{(i)})\Big(\theta^T x^{(i)} + ln(1+e^{-\theta^T x^{(i)}})\Big)\Big) =$$

$$\frac{1}{m}\sum_{i=1}^{m}\Big(ln\Big(e^{\theta^T x^{(i)}}(1+e^{-\theta^T x^{(i)}})\Big) - y^{(i)}\theta^T x^{(i)}\Big) =$$

$$= \frac{1}{m}\sum_{i=1}^{m}\Big(ln(1+e^{\theta^T x^{(i)}}) - y^{(i)}\theta^T x^{(i)}\Big)$$

By taking the derivative of the above relation w.r.t the learnable parameters $\theta \in \mathbb{R}^n$ we get that

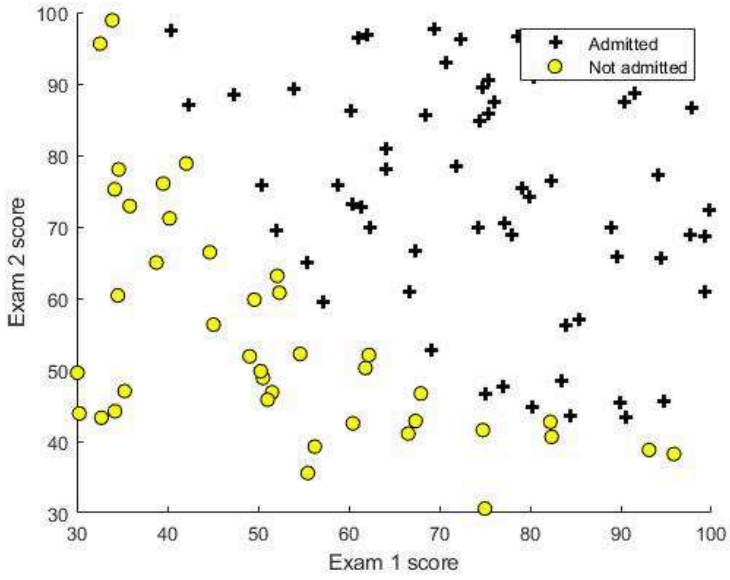
$$\frac{\partial J(\theta)}{\partial \theta} = \frac{1}{m}\sum_{i=1}^{m}\Big(\frac{x^{(i)}e^{\theta^T x^{(i)}}}{1+e^{\theta^T x^{(i)}}} - y^{(i)}x^{(i)}\Big) = \frac{1}{m}\sum_{i=1}^{m}(\frac{1}{1+e^{-\theta^T x^{(i)}}} - y^{(i)})x^{(i)}.$$

Proving that

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m}\sum_{i=1}^{m}(h_\theta(x^{(i)}) - y^{(i)})x_j^{(i)}.$$

B.

Χρησιμοποιώντας τη λογιστική παλινδρόμηση, για να προβλέψουμε αν ένας μαθητής γίνει δεκτός σε ένα πανεπιστήμιο, με βάση τους βαθμούς του σε 2 εξετάσεις, πήραμε τα παρακάτω αποτελέσματα. Αρχικά προβάλλουμε τα δεδομένα:

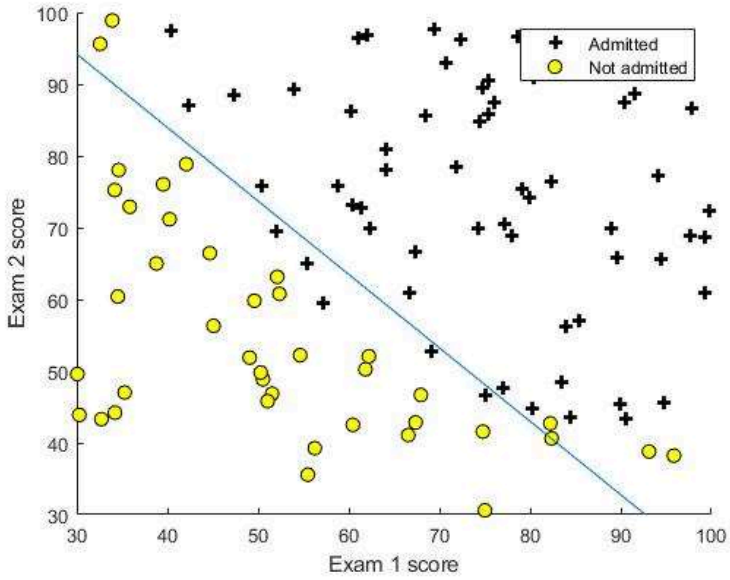


Υλοποιώντας τις συναρτήσεις που μας ζητήθηκαν και εκτελώντας τον κώδικα, είχαμε τα εξής αποτελέσματα:

Κόστος και κλίση:

```
Cost at initial theta (zeros): 0.693147
Gradient at initial theta (zeros):
 -0.100000
 -12.009217
 -11.262842
```

Γράφημα από την plotDecisionBoundary:



Με βελτιστοποίηση:

```
Cost at theta found by fminunc: 0.203498
theta:
 -25.161343
 0.206232
 0.201472
```

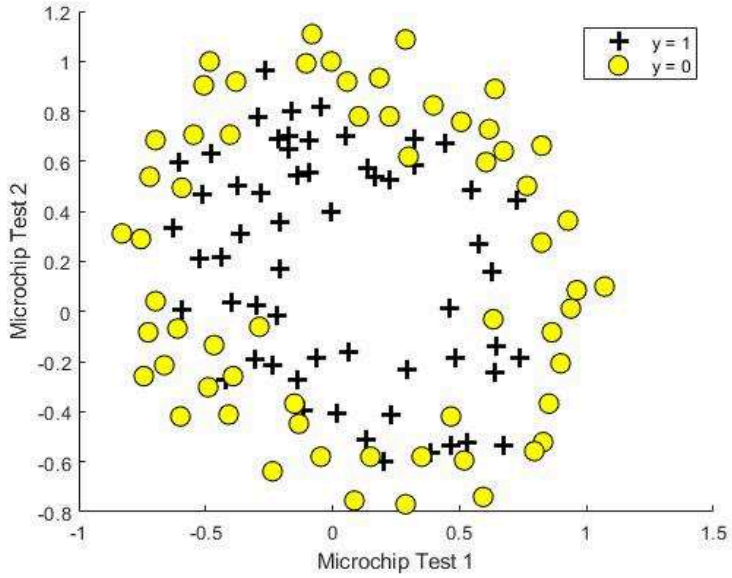
Πρόβλεψη αν ο φοιτητής γίνει δεκτός:

```
Program paused. Press enter to continue.
For a student with scores 45 and 85, we predict an admission probability of 0.776291

Train Accuracy: 89.000000
```

2. Λογιστική Παλινδρόμηση με Ομαλοποίηση

Εδώ εφαρμόσαμε ομαλοποιημένη λογιστική παλινδρόμηση, για την πρόβλεψη ελέγχου ποιότητας στα μικροτσίπ μιας μονάδας κατασκευής. Αρχικά προβάλλουμε τα δεδομένα:



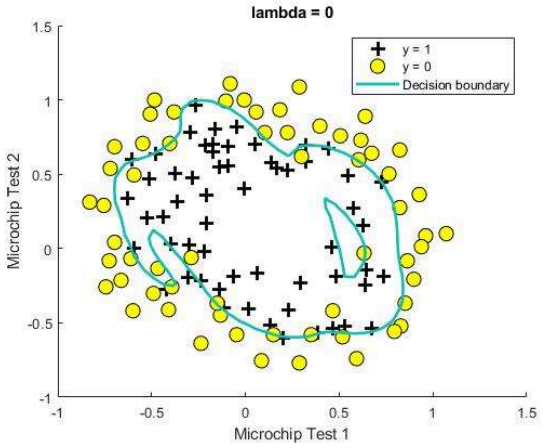
Με μαύρο απεικονίζονται όσα έχουν ελεγχθεί και είναι ποιοτικά, ενώ με κίτρινο όσα δεν είναι ποιοτικά.

Προχωρώντας τον κώδικα έχουμε:

```
Cost at initial theta with lambda = 1 (zeros): 0.693147
Expected cost (approx): 0.693
Gradient at initial theta (zeros) - first five values only:
    0.008475
    0.018788
    0.000078
    0.050345
    0.011501
Expected gradients (approx) - first five values only:
    0.0085
    0.0188
    0.0001
    0.0503
    0.0115
```

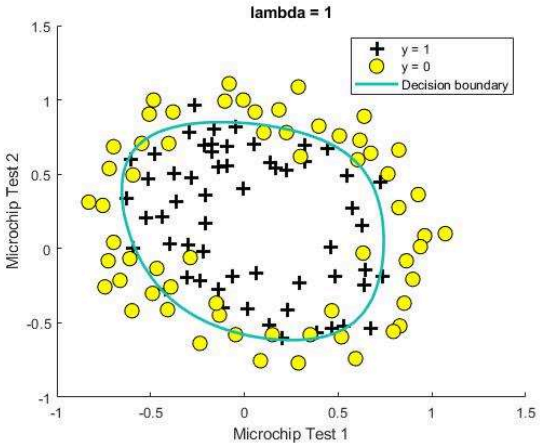
```
Cost at test theta (with lambda = 10): 3.164509
Expected cost (approx): 3.16
Gradient at test theta - first five values only:
    0.346045
    0.161352
    0.194796
    0.226863
    0.092186
Expected gradients (approx) - first five values only:
    0.3460
    0.1614
    0.1948
    0.2269
    0.0922
```

Και τα σύνορα απόφασης για διάφορες τιμές του λ:



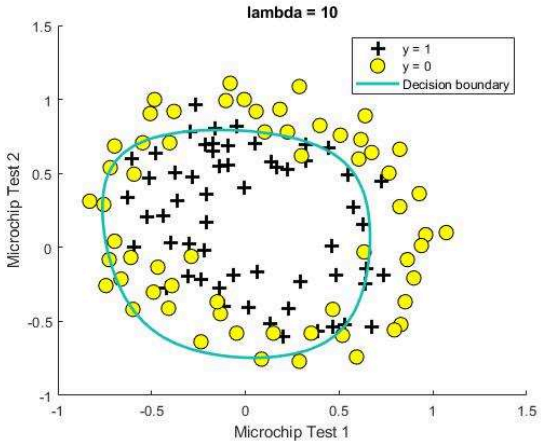

```
Train Accuracy: 88.983051
```

```
Expected accuracy (with lambda = 0):
89(approx)
```



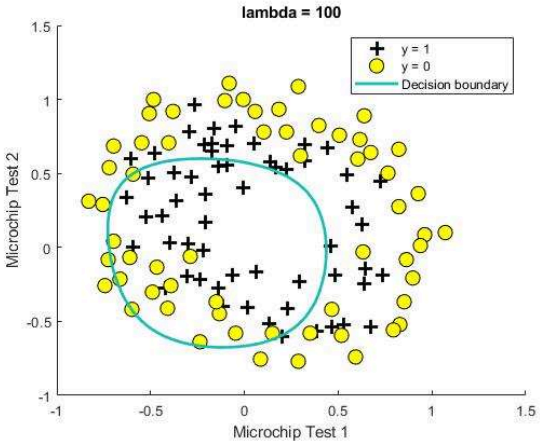

```
Train Accuracy: 83.050847
```

```
Expected accuracy (with lambda = 1):
83.1(approx)
```




```
Train Accuracy: 74.576271
```

```
Expected accuracy (with lambda = 10):
74.6(approx)
```




```
Train Accuracy: 61.016949
```

```
Expected accuracy (with lambda = 100):
61(approx)
```

3. Εκτίμηση Παραμέτρων (Maximum Likelihood)

Ο M-L.E. είναι η λύση του ακόλουθου προβλήματος μεγιστοποίησης:

$$\hat{\lambda} = \arg\max_{\lambda} l(\lambda; x_1, \ldots, x_n)$$

Η 1η συνθήκη για μέγιστο είναι:

$$\frac{d}{d\lambda} l(\lambda; x_1, \ldots, x_n) = 0$$

Η 1η παράγωγος της πιθανότητας log-likelihood, σε σχέση με την παράμετρο λ είναι:

$$\frac{d}{d\lambda} l(\lambda; x_1, \ldots, x_n) = \frac{d}{d\lambda}\left(-n\lambda - \sum_{j-1}^{n} \ln(x_j!) + \ln(\lambda) \sum_{j-1}^{n} x_j \right)$$

$$= -n + \frac{1}{\lambda} \sum_{j-1}^{n} x_j$$

Η παράγωγος της πιθανότητας πρέπει να είναι μηδέν, σύμφωνα με την συνθήκη που αναφέρουμε παραπάνω. Οπότε τελικά έχουμε:

$$\lambda = \frac{1}{n} \sum_{j-1}^{n} x_j$$

Μια πιο ακριβής λύση είναι η εξής:

Suppose we have n i.i.d samples $D = \{x_1, ..., x_n\}$ that are generated from a Poisson distribution that is parameterized by λ.

$$p(x|\lambda)\frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \ldots \quad , \quad \lambda > 0$$

We will attend to find the MLE of parameters λ. The likelihood function is

$$L_D(\lambda) = \prod_{i=1}^{n} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}.$$

The log-likelihood then is

$$l_D(\lambda) = log(\prod_{i=1}^{n} \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}) = \sum_{i=1}^{n} log(\frac{\lambda^{x_i} e^{-\lambda}}{x_i!}) =$$

$$= \sum_{i=1}^{n} (-\lambda + x_i log\lambda - log x_i!) = -n\lambda - \sum_{i=1}^{n} log x_i! + log\lambda \sum_{i=1}^{n} x_i.$$

The Maximum Likelihood Estimation of λ can be found by solving the convex optimization problem $\text{argmax}_\lambda(l_D(\lambda))$. (This optimization problem is convex because we are maximizing a concave function).

$$\nabla_{\lambda_{MLE}} l_D(\lambda) = 0 \Leftrightarrow -n + \frac{1}{\lambda_{MLE}} \sum_{i=1}^{n} x_i = 0$$

$$\Leftrightarrow \lambda_{MLE} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Therefore, λ_{MLE} is just the sample mean of the n observations in the sample.

4. Εκτίμηση Παραμέτρων και Ταξινόμηση (ML - Naive Bayes Classifier)

Εδώ, υλοποιήσαμε τον naive Bayes ταξινομητή για αναγνώριση προτύπων. Τα ψηφία 0 έως 9 αντιστοιχούν σε 10 κλάσεις και κάθε δείγμα είναι αναπαράσταση μιας εικόνας με διαστάσεις 28x28. Στην περίπτωσή μας, υποθέτουμε ότι τα χαρακτηριστικά (εικονοστοιχεία-pixels) είναι ανεξάρτητα. Χρησιμοποιώντας την κατανομή Bernoulli, μοντελοποιούμε κάθε pixel από κάθε κλάση.

A.

$$L_{D_{x^{y_i}}} = P(D_{x^{y_i}}|p^{y_i}) = \prod_{j=1}^{n} P(X = x_j^{y_i}) = (p^{y_i})^k (1-p^{y_i})^{k'}$$

where $k = \sum_{j=1}^{n} x_j^{y_i}$ and $k' = n - k$.

$$l_{D_{x^{y_i}}}(p^{y_i}) = log((p^{y_i})^k (1-p^{y_i})^{k'}) = klog(p^{y_i}) + k'log(1-p^{y_i})$$

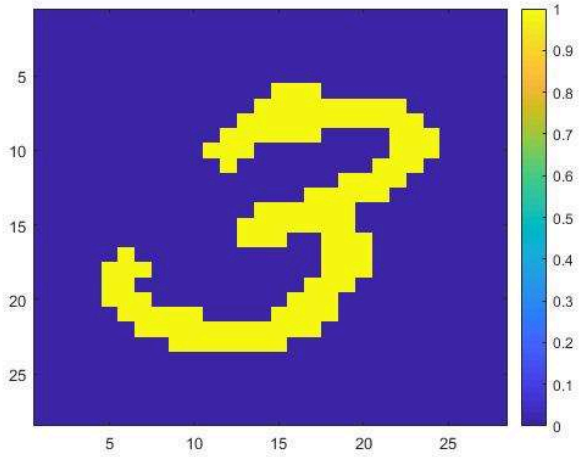
$$\nabla_{p_{MLE}^{y_i}} l_{D_{x^{y_i}}}(p^{y_i}) = 0 \Leftrightarrow \frac{k}{p_{MLE}^{y_i}} - \frac{k'}{1-p_{MLE}^{y_i}} = 0$$

$$\frac{k - kp_{MLE}^{y_i} - k'p_{MLE}^{y_i}}{p_{MLE}^{y_i}(1-p_{MLE}^{y_i})} = 0 \Leftrightarrow p_{MLE}^{y_i} = \frac{k}{k+k'}$$

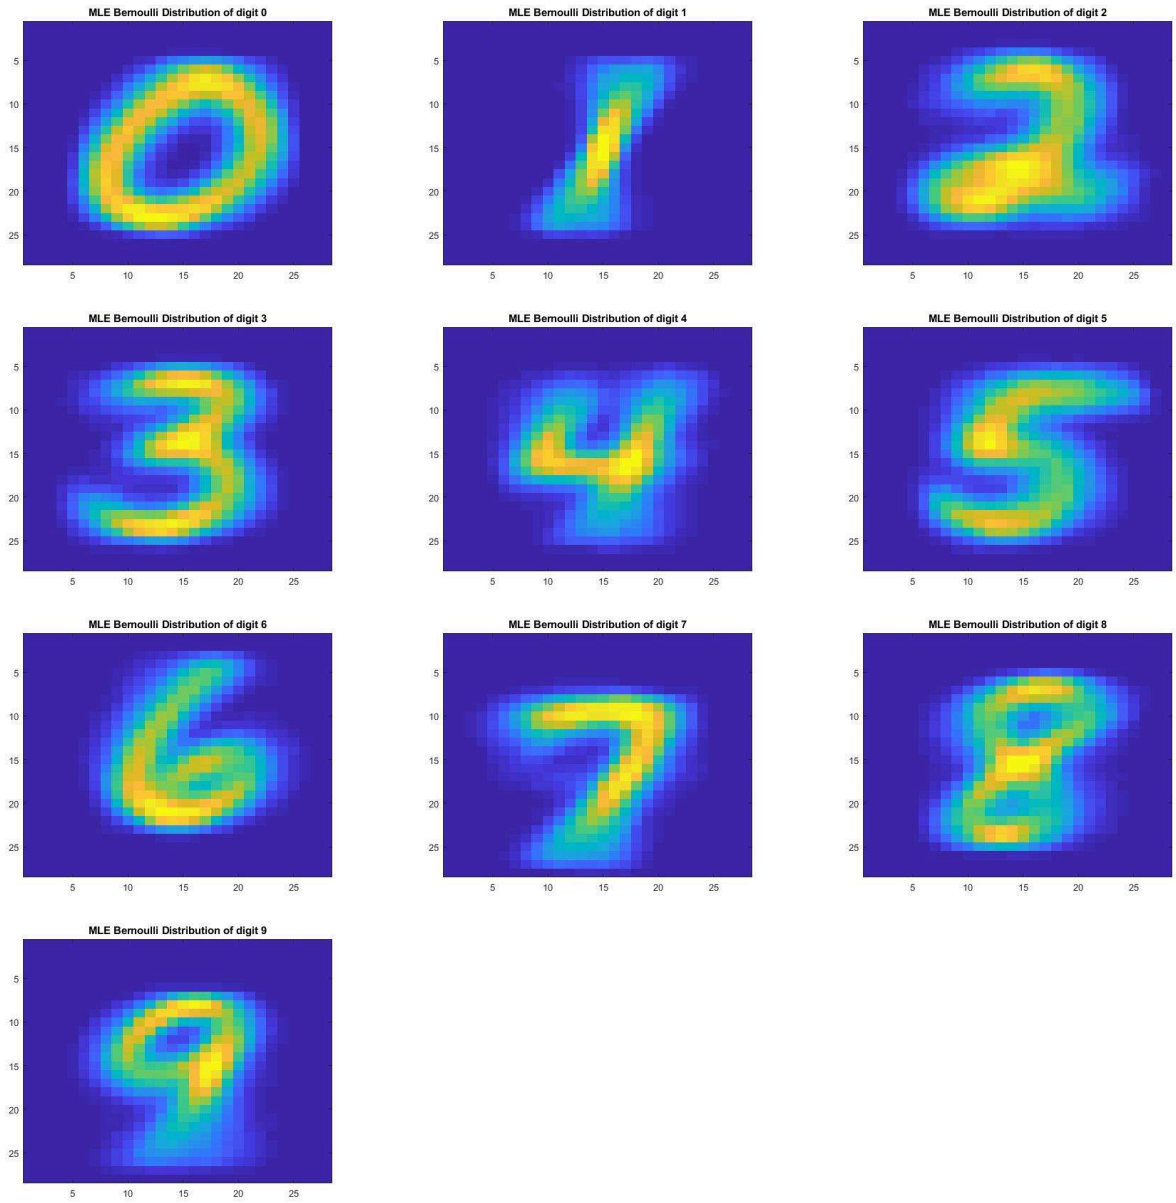
$$p_{MLE}^{y_i} = \frac{1}{n}\sum_{j=1}^{n} x_j^{y_i}$$

B.

Παρακάτω στα γραφήματα, χρησιμοποιώντας τα δοσμένα δείγματα εκπαίδευσης, για κάθε ψηφίο χρησιμοποιούμε τους εκτιμητές μέγιστης πιθανοφάνειας. Τρέχοντας τον κώδικα που δόθηκε ως παράδειγμα είχαμε την εξής εικόνα:



Μετά την εκπαίδευση κάθε ψηφίου, χρησιμοποιώντας την κατανομή Bernoulli έχουμε:



C. Ταξινόμηση και ακρίβεια

Για να ταξινομήσουμε ένα δείγμα ελέγχου $\boldsymbol{x} = (x_1, \ldots, x_{784})$ υπολογίζουμε, για κάθε ψηφίο y, την πιθανοφάνεια του δείγματος. Επειδή τα pixels θεωρούνται ανεξάρτητα, η πιθανοφάνεια είναι το γινόμενο των κατανομών Bernoulli όλων των pixels:

$$p(\boldsymbol{x} \mid y) = \prod_i (p^{y_i})^{x_i} (1 - p^{y_i})^{1 - x_i}$$

Το γινόμενο 784 αριθμών μικρότερων της μονάδας είναι πάρα πολύ μικρό, γι' αυτό στον κώδικα χρησιμοποιούμε τον λογάριθμό του:

$$\ln p(\boldsymbol{x} \mid y) = \Sigma_i \, [\, x_i \ln p^{y_i} + (1 - x_i) \ln(1 - p^{y_i}) \,]$$

Κάθε δείγμα ανατίθεται στο ψηφίο με τη μεγαλύτερη τιμή. Οι εκ των προτέρων πιθανότητες των κλάσεων είναι ίσες (500 δείγματα εκπαίδευσης για κάθε ψηφίο), οπότε δεν επηρεάζουν την απόφαση και παραλείπονται. Πολλά pixels έχουν εκτιμητή ακριβώς 0 (είναι σβηστά σε όλα τα δείγματα εκπαίδευσης του ψηφίου, όπως τα pixels στα άκρα της εικόνας), με αποτέλεσμα ο

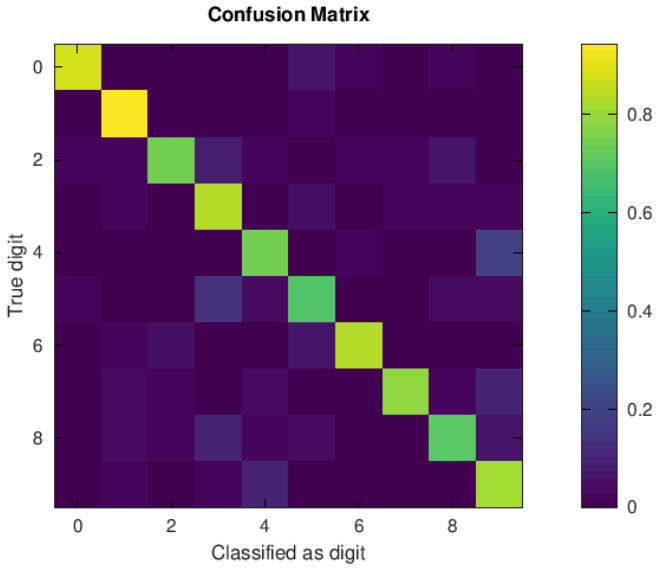
λογάριθμος να απειρίζεται. Για τον λόγο αυτό περιορίζουμε τις παραμέτρους στο διάστημα $[10^{-10}, 1 - 10^{-10}]$ πριν πάρουμε τους λογαρίθμους.

Στην αρχική έκδοση της εργασίας, αντί για το γινόμενο είχαμε χρησιμοποιήσει τον μέσο όρο των πιθανοτήτων των pixels, κάτι που δεν αντιστοιχεί στον naive Bayes ταξινομητή και έδινε ακρίβεια μόλις 0.53. Με τη σωστή συνάρτηση πιθανοφάνειας ταξινομούνται σωστά 3991 από τα 5000 δείγματα ελέγχου, δηλαδή η ακρίβεια της ταξινόμησης είναι **0.7982 (79.82%)**.

Ο πίνακας confusion matrix (πλήθος δειγμάτων, 500 δείγματα ελέγχου ανά ψηφίο) είναι:

Πραγματικό ψηφίο	**Ταξινομήθηκε ως**									
	0	**1**	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**
0	**441**	0	1	0	2	30	13	0	12	1
1	0	**472**	2	3	0	13	4	0	6	0
2	8	12	**376**	37	8	2	8	13	32	4
3	1	10	4	**416**	5	23	5	13	10	13
4	1	1	7	0	**371**	5	13	3	5	94
5	14	2	3	67	19	**346**	7	6	16	20
6	7	9	28	0	6	33	**414**	0	3	0
7	1	19	8	3	16	0	0	**396**	10	47
8	5	16	13	49	11	18	1	3	**349**	35
9	3	8	3	8	50	7	0	6	5	**410**

Διαιρώντας κάθε γραμμή με το πλήθος των δειγμάτων ελέγχου του ψηφίου (500), το στοιχείο (i, j) δείχνει πόσο συχνά το ψηφίο i ταξινομείται ως ψηφίο j. Η γραφική απεικόνιση του κανονικοποιημένου πίνακα είναι η παρακάτω:



Παρατηρούμε ότι ο πίνακας έχει πλέον έντονη διαγώνιο. Το ψηφίο που αναγνωρίζεται καλύτερα είναι το 1 (94.4%) και ακολουθεί το 0 (88.2%), ενώ τα δυσκολότερα είναι το 5 (69.2%) και το 8 (69.8%). Τα περισσότερα λάθη γίνονται ανάμεσα σε ψηφία με παρόμοιο σχήμα: το 4 ταξινομείται ως 9 σε 94 δείγματα (18.8%) και το 9 ως 4 σε 50 (10%), το 5 ως 3 σε 67 (13.4%), το 8 ως 3 σε 49 (9.8%) και το 7 ως 9 σε 47 (9.4%). Αυτό είναι αναμενόμενο, αφού τα μοντέλα των ψηφίων αυτών

(εικόνες του ερωτήματος Β) επικαλύπτονται σε μεγάλο μέρος των pixels και η υπόθεση της ανεξαρτησίας των pixels δεν λαμβάνει υπόψη το σχήμα του ψηφίου συνολικά.

5. Bayesian εκτίμηση παραμέτρου (Bayesian Inference)

Σε αυτή την άσκηση, μελετήσαμε την Bayesian εκτίμηση του μ. Σε ένα σύνολο $H(n)$ με $n = 25$ μετρήσεις, υποθέτοντας ότι η συνάρτηση πυκνότητας πιθανότητας των μετρήσεων είναι Gaussian, με γνωστή τυπική απόκλιση $\sigma = 1.25$, και ότι η εκ των προτέρων κατανομή της μέσης τιμής είναι επίσης Gaussian, $p(\mu) \sim N(\mu_0, \sigma_0^2)$ με $\mu_0 = 0$.

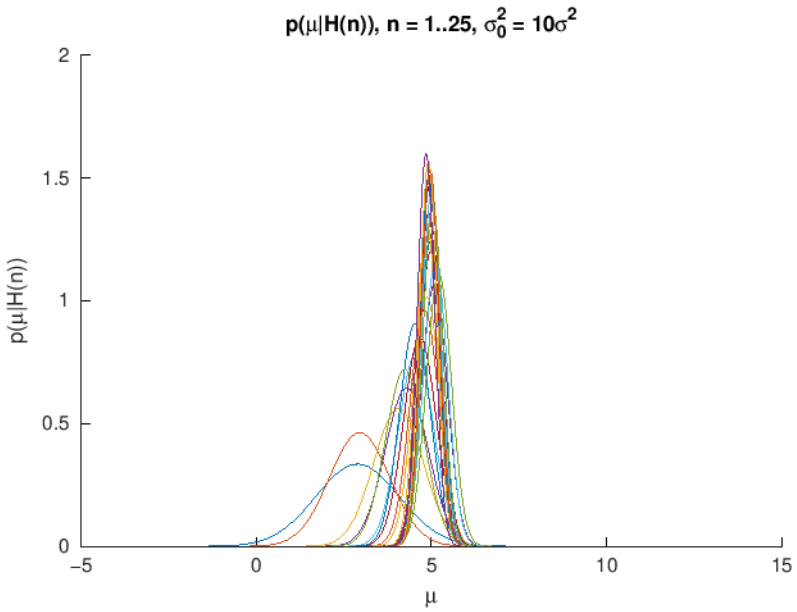
Με Gaussian πιθανοφάνεια και Gaussian εκ των προτέρων κατανομή, η εκ των υστέρων κατανομή του μ είναι και αυτή Gaussian, $p(\mu \mid H(n)) \sim N(\mu_n, \sigma_n^2)$, με

$$\mu_n = (n \sigma_0^2 m_n + \sigma^2 \mu_0) / (n \sigma_0^2 + \sigma^2), \quad \sigma_n^2 = \sigma_0^2 \sigma^2 / (n \sigma_0^2 + \sigma^2)$$

όπου m_n είναι ο μέσος όρος των n πρώτων μετρήσεων. Οι μετρήσεις διαβάζονται από το αρχείο `data_2_5.txt` και ο μέσος όρος και των 25 είναι $m_{25} = 4.8674$.

Α. Η πυκνότητα p(μ | H(n))

Για $\sigma_0^2 = 10\sigma^2$ σχεδιάσαμε σε κοινό γράφημα τη δεσμευμένη πυκνότητα πιθανότητας $p(\mu \mid H(n))$, καθώς το n μεταβάλλεται από 1 έως 25:



Για $n = 1$ η κατανομή είναι πλατιά ($\mu_1 = 2.8912$, $\sigma_1 = 1.1918$), αφού έχουμε μόνο μία μέτρηση. Όσο αυξάνεται το n, η καμπύλη στενεύει και ψηλώνει και το κέντρο της πλησιάζει τον μέσο όρο των μετρήσεων: για $n = 5$ έχουμε $\mu_5 = 4.2445$ και $\sigma_5 = 0.5535$, ενώ για $n = 25$ έχουμε $\mu_{25} = 4.8480$ και $\sigma_{25} = 0.2495$. Δηλαδή η αβεβαιότητα για το μ μειώνεται καθώς βλέπουμε περισσότερα δεδομένα. Επειδή το σ_0^2 είναι μεγάλο, η εκ των προτέρων πληροφορία ($\mu_0 = 0$) επηρεάζει ελάχιστα το αποτέλεσμα.

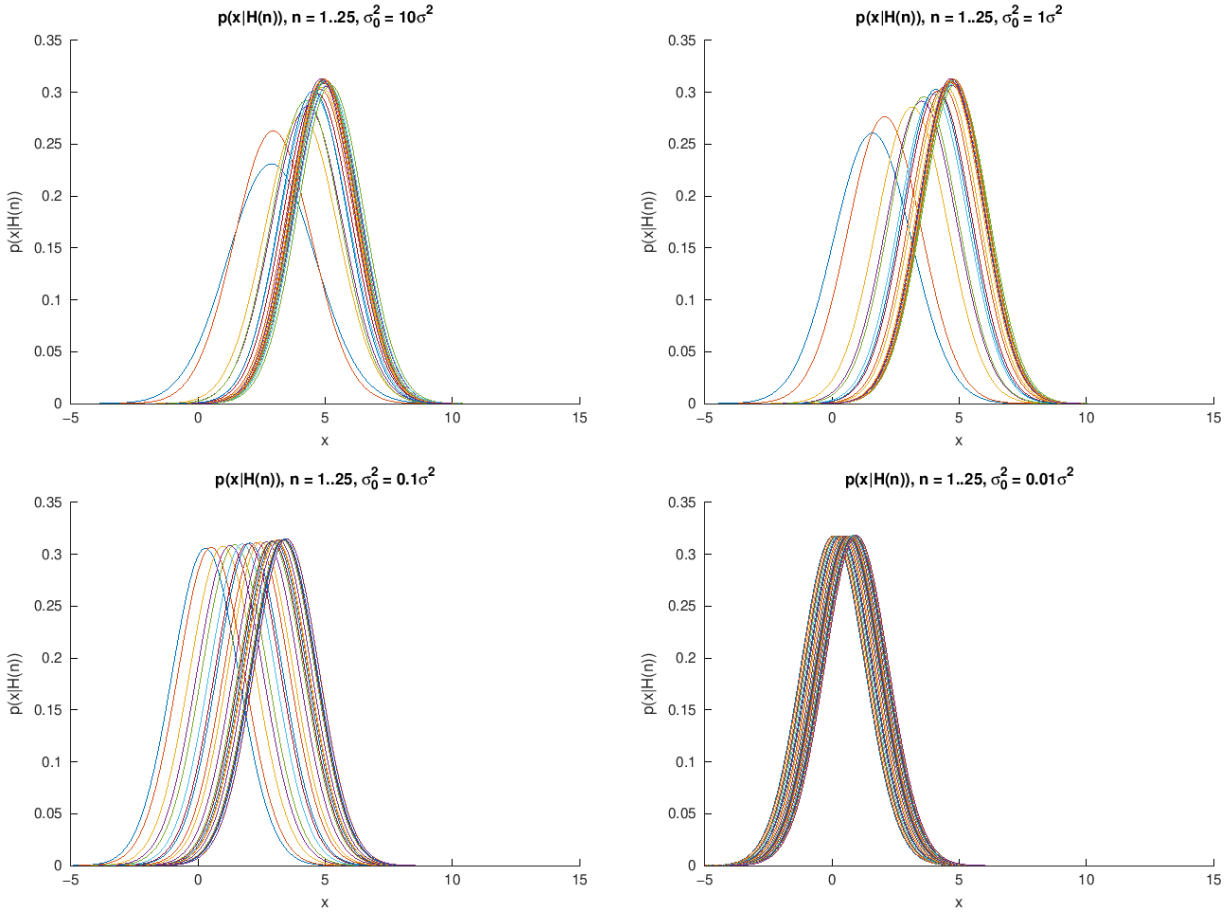
Β. Η πυκνότητα p(x | H(n))

Η δεσμευμένη πυκνότητα μιας νέας μέτρησης x προκύπτει ολοκληρώνοντας ως προς το μ, $p(x \mid H(n)) = \int p(x \mid \mu)\, p(\mu \mid H(n))\, d\mu$, και είναι Gaussian με την ίδια μέση τιμή μ_n αλλά μεγαλύτερη

διασπορά:

$$p(x \mid H(n)) \sim \mathrm{N}(\mu_n, \sigma^2 + {\sigma_n}^2)$$

Στη διασπορά σ^2 των μετρήσεων προστίθεται δηλαδή η αβεβαιότητα ${\sigma_n}^2$ που έχουμε για το μ. Τα γραφήματα για $n = 1, \ldots, 25$ και για τις τέσσερις τιμές του ${\sigma_0}^2$ είναι:



Η πυκνότητα $p(x \mid H(n))$, $n = 1, \ldots, 25$, για ${\sigma_0}^2 = 10\sigma^2$ (πάνω αριστερά), ${\sigma_0}^2 = \sigma^2$ (πάνω δεξιά), ${\sigma_0}^2 = 0.1\sigma^2$ (κάτω αριστερά) και ${\sigma_0}^2 = 0.01\sigma^2$ (κάτω δεξιά).

${\sigma_0}^2$	$n = 1$		$n = 5$		$n = 25$	
	μέση τιμή	**τυπ. απόκλιση**	**μέση τιμή**	**τυπ. απόκλιση**	**μέση τιμή**	**τυπ. απόκλιση**
$10\sigma^2$	2.8912	1.7271	4.2445	1.3671	4.8480	1.2747
σ^2	1.5901	1.5309	3.6079	1.3502	4.6802	1.2738
$0.1\sigma^2$	0.2891	1.3056	1.4431	1.2910	3.4767	1.2677
$0.01\sigma^2$	0.0315	1.2562	0.2062	1.2559	0.9735	1.2550

Μέση τιμή και τυπική απόκλιση της $p(x \mid H(n))$.

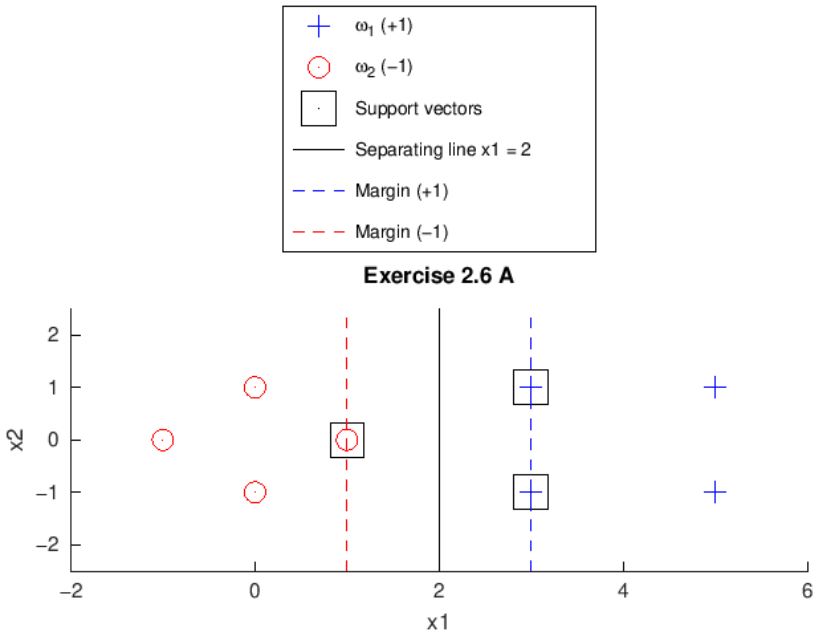
Παρατηρούμε ότι όσο αυξάνεται το n, η τυπική απόκλιση της $p(x \mid H(n))$ πλησιάζει τη γνωστή τιμή $\sigma = 1.25$, αφού η αβεβαιότητα για το μ μηδενίζεται. Η διαφορά ανάμεσα στις τέσσερις περιπτώσεις βρίσκεται κυρίως στη θέση της κατανομής. Για ${\sigma_0}^2 = 10\sigma^2$ η μέση τιμή φτάνει στο 4.8480 μετά από

25 μετρήσεις, πολύ κοντά στον μέσο όρο του δείγματος (4.8674), ενώ για $\sigma_0^2 = 0.01\sigma^2$ μετακινείται μόλις μέχρι το 0.9735.

Αποδεικνύεται από τα γραφήματα, ότι όταν το σ_0^2 είναι μεγάλο, η εκτίμηση της μέσης τιμής συγκλίνει γρηγορότερα στο μέσο όρο του δείγματος των μετρήσεων του χρόνου. Όταν το σ_0^2 είναι μικρό, η επίδραση του μέσου όρου του δείγματος στην εκτίμηση της μέσης τιμής είναι λιγότερη, κάνοντάς την να παραμένει κοντά στο $\mu_0 = 0$.

6. Support Vector Machines (Αναλυτική βελτιστοποίηση με KKT)

Α.1 Σχεδίαση των δειγμάτων και διαισθητική λύση



Τα δείγματα της ω_1 (σταυροί) και της ω_2 (κύκλοι). Σε τετράγωνο είναι τα support vectors. Η συνεχής κατακόρυφη γραμμή είναι η ευθεία διαχωρισμού $x_1 = 2$ και οι διακεκομμένες ($x_1 = 1$ και $x_1 = 3$) τα όρια του περιθωρίου.

Τα δείγματα των δύο κλάσεων που βρίσκονται πιο κοντά μεταξύ τους είναι τα $[3, 1]^T$ και $[3, -1]^T$ της ω_1 και το $[1, 0]^T$ της ω_2. Αυτά είναι τα support vectors. Διαισθητικά, το υπερεπίπεδο με το μέγιστο περιθώριο είναι η κατακόρυφη ευθεία $x_1 = 2$, που βρίσκεται στη μέση ανάμεσα στην ευθεία $x_1 = 3$ (όπου βρίσκονται τα δύο support vectors της ω_1) και στο σημείο $[1, 0]^T$. Η απόσταση κάθε support vector από την ευθεία είναι 1, άρα το πλάτος του περιθωρίου είναι 2. Οποιαδήποτε στροφή ή μετατόπιση της ευθείας θα έφερνε κάποιο από τα τρία αυτά δείγματα πιο κοντά της.

Α.2 Αναλυτική λύση με τις συνθήκες KKT

Θέτουμε $y_i = +1$ για την ω_1 και $y_i = -1$ για την ω_2. Ελαχιστοποιούμε το $\frac{1}{2}\|\boldsymbol{w}\|^2$ με τους περιορισμούς $y_i(\boldsymbol{w}^T\boldsymbol{x}_i + w_0) \geq 1$. Η Λαγκρανζιανή είναι

$$L(\boldsymbol{w}, w_0, \boldsymbol{\lambda}) = \tfrac{1}{2}\|\boldsymbol{w}\|^2 - \Sigma_i \lambda_i [\, y_i(\boldsymbol{w}^T\boldsymbol{x}_i + w_0) - 1 \,]$$

και οι συνθήκες KKT είναι:

$$\text{(i) } \boldsymbol{w} = \Sigma_i \lambda_i y_i \boldsymbol{x}_i, \quad \text{(ii) } \Sigma_i \lambda_i y_i = 0, \quad \text{(iii) } \lambda_i \geq 0, \quad \text{(iv) } \lambda_i [\, y_i(\boldsymbol{w}^T\boldsymbol{x}_i + w_0) - 1 \,] = 0$$

Υποθέτουμε ότι μόνο τα τρία support vectors έχουν $\lambda \neq 0$: λ_1 για το $[3, 1]^T$, λ_2 για το $[3, -1]^T$ και λ_3 για το $[1, 0]^T$. Από τη (ii) έχουμε $\lambda_1 + \lambda_2 = \lambda_3$ και από την (i):

$$\boldsymbol{w} = \lambda_1[3, 1]^T + \lambda_2[3, -1]^T - \lambda_3[1, 0]^T = [3\lambda_1 + 3\lambda_2 - \lambda_3,\ \lambda_1 - \lambda_2]^T = [2\lambda_3,\ \lambda_1 - \lambda_2]^T$$

Από τη (iv), για τα τρία αυτά δείγματα οι περιορισμοί ισχύουν ως ισότητες:

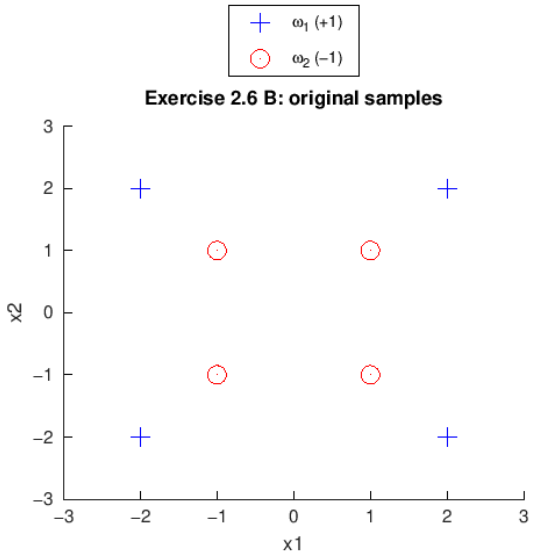
$$3w_1 + w_2 + w_0 = 1, \quad 3w_1 - w_2 + w_0 = 1, \quad w_1 + w_0 = -1$$

Αφαιρώντας τις δύο πρώτες βρίσκουμε $w_2 = 0$, άρα $\lambda_1 = \lambda_2$. Αφαιρώντας την τρίτη από την πρώτη βρίσκουμε $2w_1 = 2$, άρα $w_1 = 1$ και $w_0 = -2$. Τέλος $2\lambda_3 = w_1 = 1$, οπότε:

$$\lambda_1 = \lambda_2 = 1/4, \quad \lambda_3 = 1/2, \quad \boldsymbol{w} = [1, 0]^T, \quad w_0 = -2$$

Όλα τα λ είναι θετικά και τα υπόλοιπα δείγματα ικανοποιούν τους περιορισμούς: για τα $[5, \pm 1]^T$ έχουμε $\boldsymbol{w}^T\boldsymbol{x} + w_0 = 3 \geq 1$, για τα $[0, \pm 1]^T$ έχουμε $-2 \leq -1$ και για το $[-1, 0]^T$ έχουμε $-3 \leq -1$. Άρα ικανοποιούνται όλες οι συνθήκες KKT και η βέλτιστη γραμμή διαχωρισμού είναι η $x_1 - 2 = 0$, δηλαδή η $x_1 = 2$, με πλάτος περιθωρίου $2/\|\boldsymbol{w}\| = 2$. Το αποτέλεσμα συμφωνεί με αυτό που προτείναμε διαισθητικά στο ερώτημα 1. Τις ίδιες τιμές ($\boldsymbol{w} = [1, 0]$, $w_0 = -2$) δίνει και το αρχείο `ex_2_6a.m`, καθώς και η αριθμητική επίλυση του δυικού προβλήματος.

Β.1 Σχεδίαση των δειγμάτων



Τα δείγματα της ω_1 (σταυροί) και της ω_2 (κύκλοι) στον αρχικό χώρο.

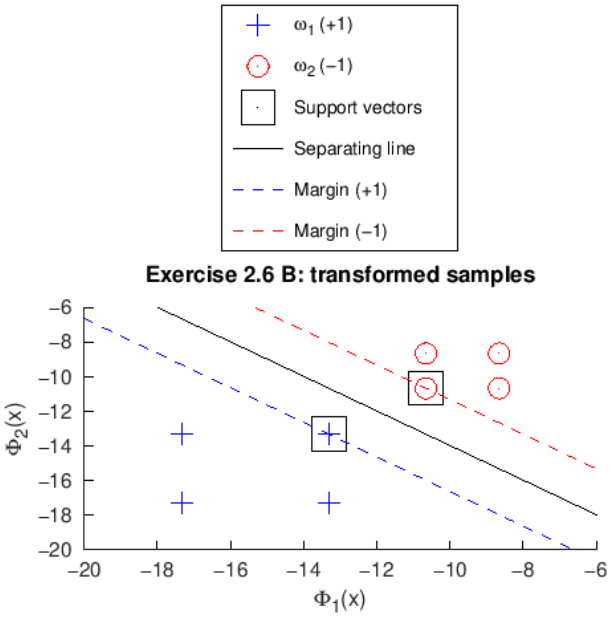
Τα δείγματα της ω_2 βρίσκονται μέσα στο τετράγωνο που σχηματίζουν τα δείγματα της ω_1. Κάθε ευθεία που αφήνει και τα τέσσερα δείγματα της ω_2 από τη μία πλευρά της αφήνει από την ίδια πλευρά και τουλάχιστον ένα δείγμα της ω_1, επομένως οι δύο κλάσεις δεν είναι γραμμικά διαχωρίσιμες. Στον αρχικό χώρο δεν υπάρχει λοιπόν γραμμικό υπερεπίπεδο διαχωρισμού και το πρόβλημα του SVM με αυστηρό περιθώριο δεν έχει λύση, οπότε δεν ορίζονται ούτε support vectors. Χρειάζεται ένας μη γραμμικός μετασχηματισμός των δειγμάτων.

Β.2 Μετασχηματισμός των δειγμάτων

Διαβάσαμε τον μετασχηματισμό της εκφώνησης ως $\Phi(\boldsymbol{x}) = \boldsymbol{x} - 4 \cdot \|\boldsymbol{x}\|_2 - 4$, δηλαδή από κάθε συνιστώσα του $\boldsymbol{x}$ αφαιρείται ο αριθμός $4\|\boldsymbol{x}\|_2 + 4$. Για τα δείγματα της ω_1 είναι $\|\boldsymbol{x}\|_2 = 2\sqrt{2}$, άρα

αφαιρείται το $8\sqrt{2} + 4 = 15.3137$, ενώ για τα δείγματα της ω_2 είναι $\|\boldsymbol{x}\|_2 = \sqrt{2}$ και αφαιρείται το $4\sqrt{2} + 4 = 9.6569$. Τα νέα διανύσματα χαρακτηριστικών είναι:

ω_1		ω_2	
$\boldsymbol{x}$	$\boldsymbol{\Phi}(\boldsymbol{x})$	$\boldsymbol{x}$	$\boldsymbol{\Phi}(\boldsymbol{x})$
[2, 2]	[−13.3137, −13.3137]	[1, 1]	[−8.6569, −8.6569]
[2, −2]	[−13.3137, −17.3137]	[1, −1]	[−8.6569, −10.6569]
[−2, −2]	[−17.3137, −17.3137]	[−1, −1]	[−10.6569, −10.6569]
[−2, 2]	[−17.3137, −13.3137]	[−1, 1]	[−10.6569, −8.6569]



Τα μετασχηματισμένα δείγματα. Σε τετράγωνο είναι τα support vectors. Η συνεχής γραμμή είναι η ευθεία διαχωρισμού και οι διακεκομμένες, που περνούν από τα support vectors, τα όρια του περιθωρίου.

Μετά τον μετασχηματισμό οι δύο κλάσεις απομακρύνονται κατά μήκος της διαγωνίου και γίνονται γραμμικά διαχωρίσιμες. Τα πλησιέστερα δείγματα των δύο κλάσεων είναι τα $\Phi([2, 2]^{\mathrm{T}})$ και $\Phi([-1, -1]^{\mathrm{T}})$, που βρίσκονται και τα δύο πάνω στη διαγώνιο. Διαισθητικά, η βέλτιστη ευθεία είναι η μεσοκάθετος του ευθύγραμμου τμήματος που τα ενώνει.

Β.3 Αναλυτική λύση με τις συνθήκες KKT

Θέτουμε $a = 2 + 8\sqrt{2} = 13.3137$ και $b = 5 + 4\sqrt{2} = 10.6569$, ώστε τα δύο support vectors να γράφονται $\boldsymbol{x}_+ = -a[1, 1]^{\mathrm{T}}$ (κλάση ω_1, $y = +1$) και $\boldsymbol{x}_- = -b[1, 1]^{\mathrm{T}}$ (κλάση ω_2, $y = -1$). Υποθέτουμε ότι μόνο αυτά έχουν $\lambda \neq 0$. Από τη συνθήκη (ii) έχουμε $\lambda_+ = \lambda_- = \lambda$ και από την (i):

$$\boldsymbol{w} = \lambda(\boldsymbol{x}_+ - \boldsymbol{x}_-) = -\lambda(a - b)[1, 1]^{\mathrm{T}}$$

Από τη (iv) οι περιορισμοί των δύο δειγμάτων ισχύουν ως ισότητες, $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_+ + w_0 = 1$ και $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_- + w_0 = -1$. Αφαιρώντας τες παίρνουμε $\boldsymbol{w}^{\mathrm{T}}(\boldsymbol{x}_+ - \boldsymbol{x}_-) = 2$, δηλαδή $\lambda\|\boldsymbol{x}_+ - \boldsymbol{x}_-\|^2 = 2\lambda(a - b)^2 = 2$, και προσθέτοντάς τες $w_0 = -\tfrac{1}{2}\,\boldsymbol{w}^{\mathrm{T}}(\boldsymbol{x}_+ + \boldsymbol{x}_-)$. Με $a - b = 4\sqrt{2} - 3 = 2.6569$ και $a + b = 23.9706$ βρίσκουμε:

$$\lambda = 1/(a - b)^2 = 0.1417, \quad \boldsymbol{w} = -[1, 1]^{\mathrm{T}}/(a - b) = [-0.3764, -0.3764]^{\mathrm{T}}, \quad w_0 = -(a + b)/(a - b) = -9.0222$$

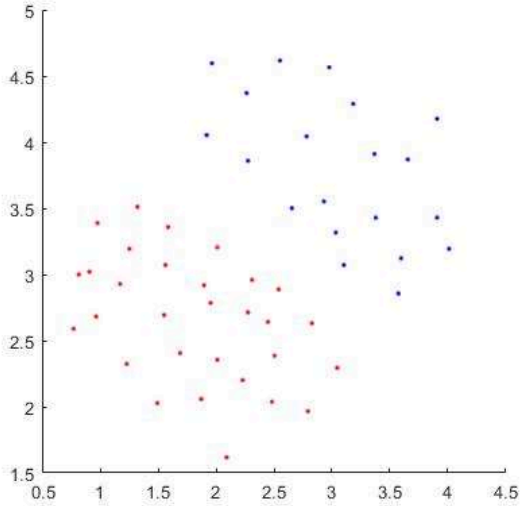
Το λ είναι θετικό και για τα υπόλοιπα έξι δείγματα οι περιορισμοί ικανοποιούνται (η μικρότερη τιμή του $y_i(\boldsymbol{w}^{\mathrm{T}}\Phi(\boldsymbol{x}_i) + w_0)$ σε όλα τα δείγματα είναι 1), άρα ισχύουν όλες οι συνθήκες ΚΚΤ. Το βέλτιστο υπερεπίπεδο διαχωρισμού στον μετασχηματισμένο χώρο είναι επομένως

$$-0.3764\,\Phi_1 - 0.3764\,\Phi_2 - 9.0222 = 0, \quad \text{δηλαδή} \quad \Phi_1 + \Phi_2 = -(a + b) = -23.9706$$

με πλάτος περιθωρίου $2/\|\boldsymbol{w}\| = \sqrt{2}(a - b) = 3.7574$, όσο και η απόσταση των δύο support vectors. Πρόκειται για τη μεσοκάθετο που προτείναμε στο ερώτημα 2. Τις ίδιες τιμές δίνει το αρχείο `ex_2_6b.m` και η αριθμητική επίλυση του δυικού προβλήματος στα μετασχηματισμένα δείγματα.

7. Support Vector Machines (Εφαρμογή σε τεχνητό σύνολο δεδομένων)

Στην άσκηση αυτή, ασχοληθήκαμε με ένα πρόβλημα βελτιστοποίησης με περιορισμούς, χρησιμοποιώντας Support Vector Machines. Θέλουμε να προβλέψουμε τις τιμές $y^{(i)}$ από τις αντίστοιχες τιμές $\boldsymbol{x}^{(i)}$, $i \in \{1, \ldots, n\}$. Αποθηκεύουμε όλα τα δεδομένα σε ένα πίνακα X, όπου οι γραμμές είναι τα δείγματα και οι στήλες τα χαρακτηριστικά. Αρχικά προβάλλουμε τα δεδομένα:



Σε όλα τα μέρη της άσκησης, η μεγιστοποίηση της Λαγκρανζιανής του δυικού προβλήματος γράφεται ως ελαχιστοποίηση της $\frac{1}{2}\boldsymbol{\lambda}^{\mathrm{T}}H\boldsymbol{\lambda} - \Sigma_i\, \lambda^{(i)}$, με $H_{ij} = y^{(i)}y^{(j)}K(\boldsymbol{x}^{(i)}, \boldsymbol{x}^{(j)})$, ώστε να λυθεί με τη συνάρτηση `quadprog`. Support vectors θεωρούμε τα δείγματα με $\lambda^{(i)} > 10^{-4}$ (για $C < 1$ το κατώφλι πολλαπλασιάζεται με το C). Τα βάρη υπολογίζονται από τη σχέση $\boldsymbol{w} = \Sigma_i\, \lambda^{(i)}y^{(i)}\boldsymbol{x}^{(i)}$, το bias ως ο μέσος όρος των $y^{(k)} - \boldsymbol{w}\cdot\boldsymbol{x}^{(k)\mathrm{T}}$ στα support vectors που βρίσκονται πάνω στο περιθώριο, και το πλάτος της λωρίδας μεταξύ των support vectors ως $2/\|\boldsymbol{w}\|$. Τα αριθμητικά αποτελέσματα που ακολουθούν υπολογίστηκαν με τον επιλυτή `qp` του GNU Octave στη θέση της `quadprog` του MATLAB και ενδέχεται να διαφέρουν ελαφρά στο MATLAB.

Μέρος 1ο: Γραμμικά διαχωρίσιμα δείγματα

Μέρος 1°: Γραμμικά διαχωρίσιμα δείγματα.

Η Λαγκρανζιανή του δυικού προβλήματος είναι

$$\tilde{L}(\lambda) = \sum_{i=1}^{n} \lambda^{(i)} - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda^{(i)} \lambda^{(j)} y^{(i)} y^{(j)} K(\boldsymbol{x}^{(i)}, \boldsymbol{x}^{(j)})$$

όπου $K(\boldsymbol{x}^{(i)}, \boldsymbol{x}^{(j)}) = \boldsymbol{x}^{(i)} \cdot (\boldsymbol{x}^{(j)})^T$

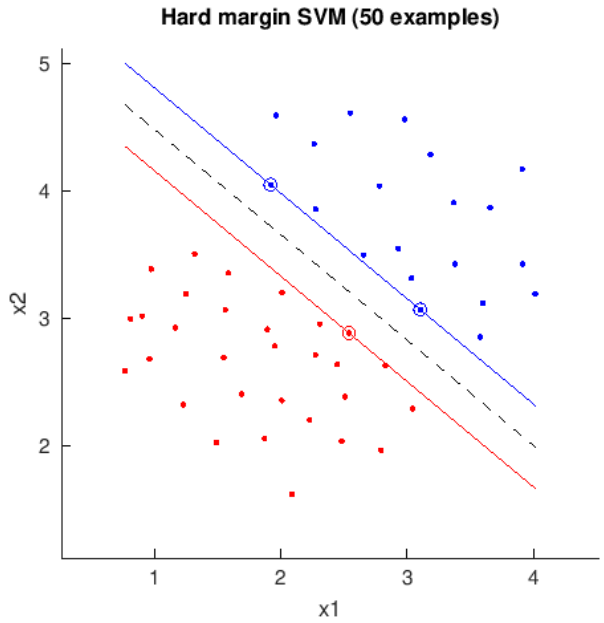
την οποία **μεγιστοποιούμε** κάτω από τους περιορισμούς

$$\lambda^{(i)} \geq 0, \quad i = 1, \ldots, n$$

$$\sum_{i=1}^{n} \lambda^{(i)} y^{(i)} = 0$$

Χρησιμοποιούμε τα 50 πρώτα παραδείγματα του αρχείου `twofeature1.txt`, τα οποία είναι γραμμικά διαχωρίσιμα, και λύνουμε το πρόβλημα με μοναδικούς περιορισμούς $\lambda^{(i)} \geq 0$ και $\Sigma_i \lambda^{(i)} y^{(i)} = 0$, χωρίς άνω φράγμα στα λ. Τα αποτελέσματα είναι:

Support vectors (δείκτες)	**λ**	***w***	w_0	**Πλάτος λωρίδας**
12, 13 ($y = +1$), 48 ($y = -1$)	6.3044, 1.6355, 7.9398	[2.5414, 3.0694]	−16.3162	0.5019



Η γραμμή διαχωρισμού (διακεκομμένη) και οι παράλληλες γραμμές που περνούν από τα support vectors (σε κύκλο), για τα 50 πρώτα παραδείγματα.

Η γραμμή διαχωρισμού είναι η $2.5414x_1 + 3.0694x_2 - 16.3162 = 0$. Μόνο τρία δείγματα έχουν $\lambda \neq 0$, δύο της κλάσης +1 και ένα της κλάσης −1, και βρίσκονται ακριβώς πάνω στις δύο παράλληλες γραμμές $\boldsymbol{w} \cdot \boldsymbol{x}^T + w_0 = \pm 1$. Όλα τα υπόλοιπα δείγματα βρίσκονται έξω από τη λωρίδα (η μικρότερη τιμή του $y^{(i)}(\boldsymbol{w} \cdot \boldsymbol{x}^{(i)T} + w_0)$ είναι 1) και κανένα δείγμα δεν ταξινομείται λάθος.

Μέρος 2ο: Μεταβλητές περιθωρίου (slack variables)

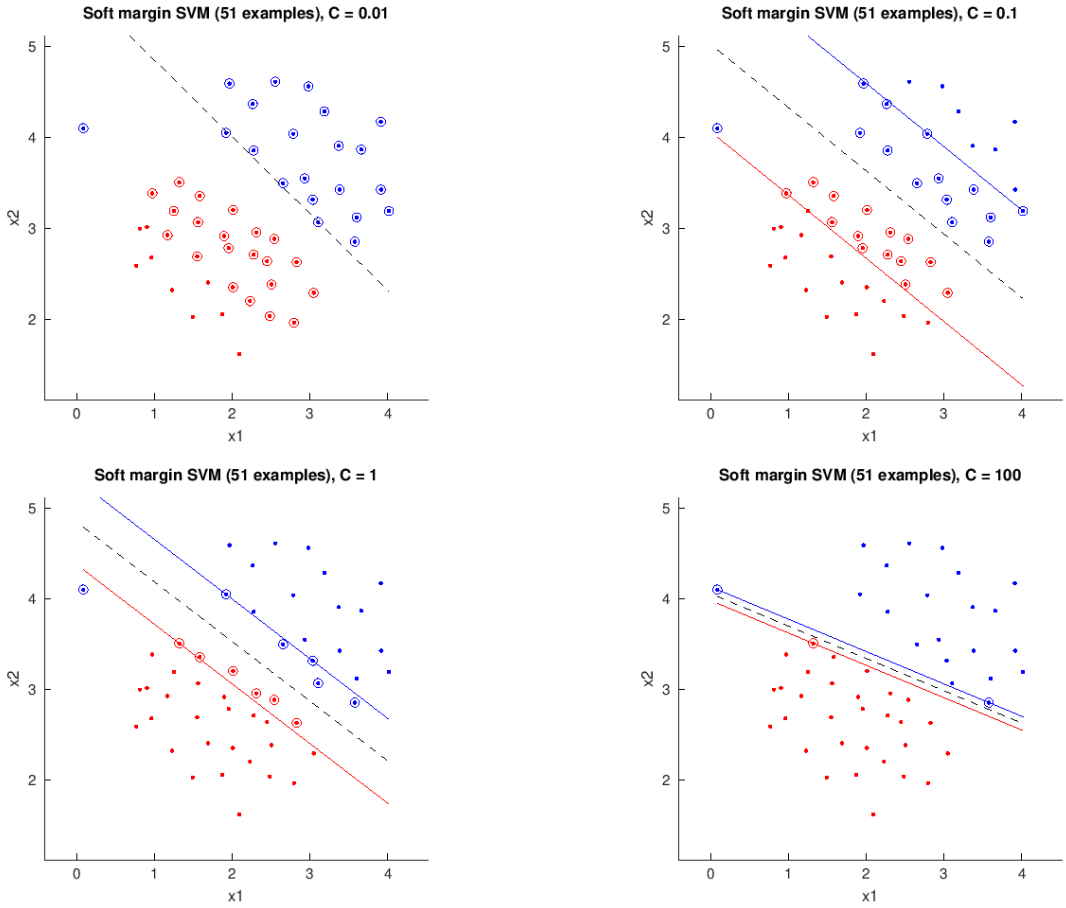
Μέρος 2°: Μεταβλητές περιθωρίου (slack variables).
Όταν υπάρχει θόρυβος στα δεδομένα χρησιμοποιούμε μεταβλητές περιθωρίου για να γίνονται ανεκτά κάποια παραδείγματα στην λάθος πλευρά της επιφάνειας απόφασης. Η παράμετρος που καθορίζει το επίπεδο ανοχής συνήθως συμβολίζεται με C και παίρνει τιμές στο διάστημα $(0, +\infty)$, με 0^+ να αντιστοιχεί σε μέγιστη ανοχή και $+\infty$ σε μηδενική ανοχή.
Η Λαγκρανζιανή του δυικού προβλήματος είναι ίδια με αυτή του πρώτου μέρους αλλά την **μεγιστοποιούμε** κάτω από τους παρακάτω περιορισμούς:

$$0 \leq \lambda^{(i)} \leq C, \quad i = 1, \dots, n$$

Επαναλάβαμε ό,τι και στο προηγούμενο μέρος, αλλά για όλα τα δεδομένα του αρχείου (51 παραδείγματα) και με τους περιορισμούς $0 \leq \lambda^{(i)} \leq C$. Το 51ο παράδειγμα ανήκει στην κλάση +1 αλλά βρίσκεται μακριά από τα υπόλοιπα δείγματα της κλάσης του, στο σημείο (0.09, 4.10). Για διάφορες τιμές του C πήραμε τα εξής αποτελέσματα:

C	Support vectors	από αυτά με $\lambda = C$	w	w_0	Πλάτος λωρίδας	Λάθος ταξινομημένα
0.01	42	42	[0.1842, 0.2181]	−1.2426	7.0058	3
0.1	28	26	[0.7240, 1.0396]	−5.2272	1.5787	1
1	12	9	[1.4067, 2.1332]	−10.3450	0.7827	1
10	7	4	[2.0522, 4.1681]	−18.2454	0.4305	1
100	3	0	[4.6838, 13.0958]	−53.1565	0.1438	0
1000	3	0	[4.6838, 13.0958]	−53.1565	0.1438	0
10000	3	0	[4.6838, 13.0958]	−53.1565	0.1438	0

Αποτελέσματα του 2ου μέρους (51 παραδείγματα). Για $C = 0.01$ όλα τα support vectors έχουν $\lambda = C$, οπότε το w_0 δεν ορίζεται μονοσήμαντα και παίρνουμε το μέσο του διαστήματος που επιτρέπουν οι συνθήκες ΚΚΤ.



Η γραμμή διαχωρισμού (διακεκομμένη), οι παράλληλες γραμμές του περιθωρίου και τα support vectors (σε κύκλο) για $C = 0.01$, 0.1, 1 και 100. Για $C = 0.01$ η λωρίδα είναι πλατύτερη από την περιοχή των δεδομένων και οι γραμμές του περιθωρίου βρίσκονται έξω από το γράφημα.

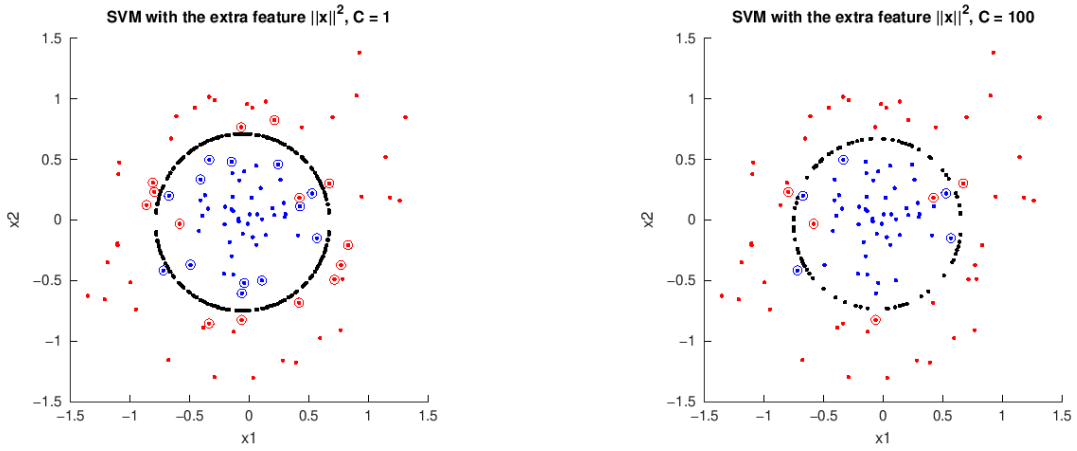
Όσο μικρότερο είναι το C, τόσο μεγαλύτερη είναι η ανοχή σε δείγματα που βρίσκονται μέσα στη λωρίδα ή στη λάθος πλευρά: η λωρίδα γίνεται πλατύτερη, ο αριθμός των support vectors αυξάνεται και το απομακρυσμένο 51ο παράδειγμα ταξινομείται λάθος, χωρίς να επηρεάζει ιδιαίτερα τη γραμμή διαχωρισμού (για $C = 0.01$ ταξινομούνται λάθος και τα παραδείγματα 12 και 13, που βρίσκονται πολύ κοντά στη γραμμή). Όσο αυξάνεται το C, τα λάθη κοστίζουν περισσότερο, η λωρίδα στενεύει και η γραμμή στρέφεται ώστε να ταξινομήσει σωστά και το 51ο παράδειγμα. Για $C \geq 100$ κανένα λ δεν φτάνει στο άνω φράγμα, όλα τα δείγματα ταξινομούνται σωστά και η λύση δεν αλλάζει άλλο (είναι η λύση με αυστηρό περιθώριο για τα 51 παραδείγματα). Το πλάτος της λωρίδας όμως πέφτει στο 0.1438, από 0.5019 που ήταν στο 1ο μέρος χωρίς το 51ο παράδειγμα. Ένα μόνο απομακρυσμένο δείγμα αρκεί δηλαδή για να αλλάξει πολύ τη λύση όταν δεν επιτρέπεται καμία ανοχή.

Μέρος 3ο: Μη γραμμικά διαχωρίσιμα παραδείγματα

Τα 100 παραδείγματα του αρχείου `twofeature2.txt` δεν είναι γραμμικά διαχωρίσιμα: τα δείγματα της κλάσης +1 βρίσκονται γύρω από την αρχή των αξόνων και περιβάλλονται από τα δείγματα της κλάσης −1. Προσθέτουμε λοιπόν σε κάθε παράδειγμα ως τρίτο χαρακτηριστικό το τετράγωνο του μέτρου του, $(x_1, x_2) \to (x_1, x_2, {x_1}^2 + {x_2}^2)$, και λύνουμε το ίδιο δυικό πρόβλημα με το 2ο μέρος ($0 \leq \lambda^{(i)} \leq C$) στα τρισδιάστατα πλέον δείγματα. Τα αποτελέσματα είναι:

C	Support vectors	w	w_0	Λάθος ταξινομημένα
0.1	61	[−0.0299, −0.1550, −1.7687]	1.1723	6
1	27	[−0.3886, −0.1391, −3.5127]	1.8639	3
10	15	[−0.7833, −0.3624, −6.0749]	2.9842	3
100	10	[−0.7149, −0.4661, −7.4458]	3.6608	3
1000	10	[−0.7149, −0.4661, −7.4458]	3.6608	3
10000	10	[−0.7149, −0.4661, −7.4458]	3.6608	3

Αποτελέσματα του 3ου μέρους (100 παραδείγματα).



Η επιφάνεια απόφασης (μαύρες κουκκίδες) και τα support vectors (σε κύκλο) στο αρχικό επίπεδο (x_1, x_2), για $C = 1$ (αριστερά) και $C = 100$ (δεξιά).

Στον χώρο των τριών χαρακτηριστικών η επιφάνεια απόφασης είναι επίπεδο, $w_1x_1 + w_2x_2 + w_3({x_1}^2 + {x_2}^2) + w_0 = 0$. Στο αρχικό επίπεδο (x_1, x_2) η ίδια εξίσωση περιγράφει κύκλο: για $C = 1$ έχει κέντρο το (−0.055, −0.020) και ακτίνα 0.731, ενώ για $C = 100$ έχει κέντρο το (−0.048, −0.031) και ακτίνα 0.704. Τα δείγματα μέσα στον κύκλο ταξινομούνται στην κλάση +1 και τα δείγματα έξω από αυτόν στην κλάση −1. Το μεγαλύτερο βάρος κατ' απόλυτη τιμή είναι το w_3, δηλαδή η ταξινόμηση βασίζεται σχεδόν αποκλειστικά στο νέο χαρακτηριστικό.

Όπως και στο 2ο μέρος, όσο αυξάνεται το C μειώνεται ο αριθμός των support vectors. Τα δεδομένα όμως δεν είναι τέλεια διαχωρίσιμα ούτε μετά την προσθήκη του τρίτου χαρακτηριστικού, γι' αυτό ακόμα και για πολύ μεγάλο C παραμένουν 3 λάθος ταξινομημένα δείγματα από τα 100, και από $C = 100$ και πάνω η λύση δεν αλλάζει. Το πλάτος της λωρίδας δεν υπολογίζεται σε αυτό το μέρος.